

Prédiction des résultats de matchs de football internationaux

Projet Fil Rouge Data Science — Cap Coupe du Monde 2026

Étudiant(e) 1 : Joud Atallah Étudiant(e) 2 : Walid Hdilou Étudiant(e) 3 : Amine Kaoutar

2026-05-21

Table of contents

1	Introduction et Contexte Métier	3
1.1	Contexte du Projet	3
1.2	Objectif Analytique	4
2	Acquisition et Préparation des Données (Data Wrangling)	4
2.1	Chapitre 1 : Acquisition Multi-Sources	4
3	 Étape 1 : Acquisition des Données & Multi-Sources	4
3.0.a	1. Initialisation de l'environnement	5
3.0.b	2. Chargement de la source de données principale	5
3.0.c	3. Intégration de données secondaires (Multi-Sources)	5
3.0.d	4. Fusion des sources	5
3.0.e	5. Consignation des données consolidées	6
3.1	Chapitre 2 : Nettoyage et Préparation (Wrangling)	6
4	 Étape 2 : Préparation & Nettoyage des Données (Data Wrangling)	6
4.0.a	1. Initialisation et imports	6
4.0.b	2. Chargement du dataset et audit initial	6
4.0.c	3. Uniformisation des formats de dates	6
4.0.d	4. Anomalies et matchs non exploitables	6
4.0.e	5. Imputation des valeurs manquantes	6
4.0.f	6. Sauvegarde des données propres	7
5	Visualisation Multidimensionnelle (Insights)	7
5.1	Chapitre 3 : Travaux Pratiques d'Exploration Visuelle	7
6	 Étape 3 : Visualisation — l'histoire du football international	7
6.0.a	1. Préparation de l'environnement	7
6.0.b	2. Chargement et préparation	7
6.0.c	3. Nombre de matchs par année	7
6.0.d	4. Tournois avec le plus de matchs	7
6.0.e	5. Équipes les plus présentes en tournois majeurs	7
6.0.f	6. Nombre moyen de buts par match et par décennie	8

6.0.g	7. Meilleurs ratios de victoires en tournois majeurs	8
6.0.h	8. Évolution du pourcentage de matchs joués par jour de la semaine	8
7	Analyse Exploratoire des Données (EDA)	8
7.1	Chapitre 4 : Travaux Pratiques d’Exploration (EDA)	8
8	 Étape 4 : Analyse Exploratoire des Données (EDA)	8
8.0.a	1. Préparation de l’environnement	8
8.0.b	2. Chargement des données nettoyées	8
8.0.c	3. Statistiques descriptives	8
8.0.d	4. Distribution des variables numériques	8
8.0.e	5. Ingénierie de variables (Feature Engineering)	9
8.0.f	6. Distribution de la cible — <code>result</code>	9
8.0.g	7. Boxplots — dispersion par classe de résultat	9
8.0.h	8. Analyse des corrélations	9
8.0.i	9. Pairplot — vision globale des relations	9
8.0.j	10. Matrice de corrélation massive (toutes les variables)	9
8.0.k	11. Le classement FIFA prédit-il le résultat ?	10
8.0.l	12. Pivot table — taux de victoire croisé	10
8.0.m	13. Binning — taux de victoire par classe d’écart de classement	10
8.0.n	14. Synthèse — insights majeurs	10
9	Modélisation et Apprentissage	11
9.1	Chapitre 5 : Travaux Pratiques de Modélisation (ML & DL)	11
10	 Étape 5 : Modélisation — Prédiction du résultat des matchs internationaux	11
10.0.a	1. Préparation de l’environnement	12
10.0.b	2. Feature engineering — l’historique de chaque équipe	12
10.0.c	3. Variables différentielles (<code>create_db</code>) et cible	12
10.0.d	4. Baseline naïve	13
10.0.e	5. Modèle 1 — Random Forest (§5.6.1 du cours, <i>Bagging</i>)	13
10.0.f	6. Modèle 2 — XGBoost (§5.6.2 du cours, <i>Boosting</i>)	14
10.0.g	7. Comparaison des modèles + matrice de confusion	14
10.0.h	8. Importance des variables	14
10.0.i	9. Prédiction des 72 matchs de la phase de groupes (CDM 2026)	14
10.0.j	10. Classement des 12 groupes — qui sort de sa poule ?	14
10.0.k	11. Synthèse — modélisation	15
11	Évaluation Métrique et Validation	15
11.1	Chapitre 6 : Travaux Pratiques d’Évaluation & Robustesse	15
12	 Étape 6 : Évaluation et phase à élimination directe	15
12.0.a	1. Préparation de l’environnement	16
12.0.b	2. Reprise du modèle du notebook 05	16
12.0.c	3. Évaluation approfondie du modèle (§6.1 du cours)	16
12.0.d	4. Optimisation des hyperparamètres (§6.2 du cours)	16
12.0.e	5. Phase à élimination directe — qui sera champion du monde ?	16
12.0.f	6. Synthèse — évaluation et prédiction finale	17

13	Data Storytelling et Communication	18
13.1	Chapitre 7 : Travaux Pratiques de Storytelling	18
14	 Étape 7 : Data Storytelling & Communication (Squelette Étudiant)	18
14.0.a	1. Préparation de l'environnement	18
14.0.b	2. Synthèse métier et Storytelling	18
14.0.c	3. Visualisation Interactive (Plotly)	18
14.1	Présentation des Résultats (Livrables Interactifs)	18
14.1.a	 Diaporama de Soutenance (RevealJS)	18
14.1.b	 Exemple de Dashboard Dynamique (OJS / Plotly)	18
15	Utilisation de l'Intelligence Artificielle	19
15.1	Cartographie de l'utilisation de l'IA	20
15.2	Principes de Rigueur et Responsabilité	20
	Bibliographie	20
	Bibliography	20

1 Introduction et Contexte Métier

Ce projet s'inscrit dans le cadre du Projet Fil Rouge de la formation Data Science & IA d'IPSSI. L'équipe a choisi de s'attaquer à une problématique d'actualité : **prédire le résultat des matchs internationaux de football**, avec en ligne de mire la Coupe du Monde FIFA 2026 organisée aux États-Unis, au Canada et au Mexique.

1.1 Contexte du Projet

Le football international est un terrain d'application particulièrement riche pour la Data Science. Les compétitions y sont nombreuses, l'enjeu économique et médiatique colossal, et les données librement disponibles couvrent **plus de 150 ans d'histoire** : le premier match international officiel oppose l'Écosse à l'Angleterre en 1872. Notre dataset principal recense aujourd'hui plus de **47 000 rencontres** entre sélections nationales.

Pourtant, prédire l'issue d'un match reste un défi. Niveau intrinsèque des équipes, dynamique récente, avantage du terrain, enjeu de la compétition, écart de classement FIFA, contexte historique — autant de signaux à combiner sans tomber dans le piège de la fuite de données (par exemple en utilisant une information qui n'existait pas encore au moment du match).

L'objectif de ce projet est de construire un pipeline de Data Science **complet et reproductible**, depuis l'acquisition des données jusqu'à un modèle prédictif rigoureusement évalué. Au-delà de l'exercice technique, l'enjeu métier est double :

- **expliquer** quels facteurs structurent réellement l'issue d'une rencontre internationale ;
- **prédire** les résultats à venir — en particulier ceux des 72 matchs programmés de la CDM 2026.

L'analyse quantitative est ici indispensable car l'intuition footballistique, aussi documentée soit-elle, ne suffit pas à arbitrer entre des hypothèses contradictoires : le classement FIFA est-il vraiment un bon prédicteur ? L'avantage à domicile résiste-t-il à l'ère des matchs en terrain neutre ? Le profil offensif d'une équipe se transmet-il d'une décennie à l'autre ? Seul un traitement statistique de l'historique permet de trancher.

1.2 Objectif Analytique

La variable cible est le **résultat du match du point de vue de l'équipe recevante**, codé en trois modalités : `home_win`, `draw`, `away_win`. Il s'agit donc d'une tâche de **classification multi-classes**.

Le couplage multi-sources est au cœur de notre démarche. Quatre jeux de données complémentaires sont fusionnés au sein du notebook `01_acquisition` :

- les **résultats historiques** (`results.csv`, dataset `martj42/international_football_results`) fournissent la trame principale — date, équipes, score, tournoi, ville, pays, neutralité du terrain ;
- les **classements FIFA mensuels** (1992–2024) ajoutent un signal de niveau relatif des équipes, joint temporellement par `pd.merge_asof` pour éviter toute fuite ;
- les jeux annexes **shootouts** (tirs au but), **goalscorers** (buteurs) et **former_names** (anciens noms d'équipes) enrichissent et fiabilisent les jointures sur l'ensemble de l'historique.

Les livrables attendus à l'issue du Jalon 1 (exploration) sont :

1. un jeu de données **propre, fusionné et historiquement cohérent** (`data/processed/matches_clean.csv`, ~30 500 matchs exploitables) ;
2. un **audit visuel** de l'histoire du football international (volume, tournois majeurs, dominantes nationales, intensité offensive, ratios de victoire) ;
3. une **analyse exploratoire** statistique dégageant **cinq insights majeurs** qui orienteront la modélisation du Jalon 2.

2 Acquisition et Préparation des Données (Data Wrangling)

Le succès de tout projet de Data Science repose sur la qualité de la préparation des données [1]. Cette section documente l'audit de qualité et les étapes de nettoyage appliquées à vos jeux de données bruts.

2.1 Chapitre 1 : Acquisition Multi-Sources

3 Étape 1 : Acquisition des Données & Multi-Sources

Cette étape correspond au premier chapitre du pipeline de Data Science : identifier, importer et consolider nos jeux de données bruts issus de différentes sources.

Projet : prédire le résultat de matchs de football internationaux, avec pour objectif final d'estimer le vainqueur de la Coupe du Monde 2026.

Sources mobilisées :

Source	Fichier	Origine
Résultats des matchs (principale)	<code>results.csv</code>	Kaggle — <i>International football results from 1872</i> (martj42)
Séances de tirs au but	<code>shootouts.csv</code>	Kaggle (martj42)

Source	Fichier	Origine
Buteurs match par match	<code>goalscorers.csv</code>	Kaggle (martj42)
Anciens noms de pays	<code>former_names.csv</code>	Kaggle (martj42)
Classement FIFA historique (1992 → 2024)	<code>fifa_ranking-2024-06-20.csv</code>	Kaggle — <i>FIFA World Ranking</i>

⚠ Le classement FIFA est **historisé** : chaque match reçoit le classement réellement en vigueur **à sa date**, et non un classement actuel. C’est indispensable pour une prédiction fiable — appliquer un classement futur à un match passé serait une *fuite de données*.

3.0.a 1. Initialisation de l’environnement

3.0.b 2. Chargement de la source de données principale

Notre jeu de données principal est `results.csv` : il recense **un match international par ligne** depuis 1872 (équipes, score, compétition, ville, pays, terrain neutre). C’est la base de notre futur modèle de prédiction.

3.0.c 3. Intégration de données secondaires (Multi-Sources)

Pour enrichir l’analyse, nous mobilisons **quatre sources complémentaires**. Les trois premières proviennent du même dataset Kaggle que les résultats. La quatrième est l’**historique du classement mondial FIFA** : une ligne = le classement d’une équipe à une date de publication donnée, depuis 1992.

3.0.d 4. Fusion des sources

C’est l’étape clé. Elle enchaîne trois opérations :

1. **Filtrage temporel** — le classement FIFA n’existe que depuis fin 1992. On ne conserve donc que les matchs joués **à partir du 31/12/1992** (les matchs antérieurs n’ont aucun classement disponible).
2. **Jointure temporelle du classement FIFA** — pour chaque match, on récupère le classement **en vigueur à sa date** grâce à `pd.merge_asof`, qui associe la dernière publication du classement *antérieure ou égale* à la date du match (`direction='backward'`). On le fait deux fois : équipe à domicile, puis équipe à l’extérieur. ⚠ Associer un classement *postérieur* au match serait une **fuite de données** et fausserait la prédiction.
3. **Jointure des tirs au but** — au niveau du match (clé : date + équipes).

Au passage, on **harmonise les noms d’équipes** : quelques pays sont orthographiés différemment dans les deux sources (ex. *USA* vs *United States*, *Czechia* vs *Czech Republic*). On aligne les noms du classement sur ceux de `results.csv` pour que la jointure fonctionne.

Les buteurs (`goalscorers`) et les anciens noms (`former_names`) sont chargés mais pas fusionnés ici : ils seront exploités plus tard (analyse des buts à l'EDA, uniformisation fine des noms au Wrangling).

3.0.e 5. Consignation des données consolidées

Nous sauvegardons le tableau consolidé dans `data/processed/`. Il servira de point d'entrée à l'étape suivante (**02 — Data Wrangling**), qui se chargera de le nettoyer.

3.1 Chapitre 2 : Nettoyage et Préparation (Wrangling)

4 Étape 2 : Préparation & Nettoyage des Données (Data Wrangling)

Cette étape correspond au deuxième chapitre du pipeline. L'objectif : **auditer** la qualité des données issues de l'acquisition, puis les **nettoyer** rigoureusement à l'aide de notre module `src/data_clean.py`.

Donnée d'entrée : `data/processed/matches_merged.csv` — les 30 583 matchs consolidés à l'étape 1 (résultats + classements FIFA historisés + tirs au but).

4.0.a 1. Initialisation et imports

4.0.b 2. Chargement du dataset et audit initial

On charge la sortie de l'étape 1 et on inspecte sa qualité : dimensions, types des colonnes, doublons et taux de valeurs manquantes.

4.0.c 3. Uniformisation des formats de dates

La colonne `date` est chargée comme du texte. On la convertit en type `datetime` et on trie les matchs par ordre chronologique via `dc.clean_dates` — indispensable pour les analyses temporelles et le futur découpage chronologique du modèle.

4.0.d 4. Anomalies et matchs non exploitables

Deux contrôles :

- **Validité des scores** — un nombre de buts est un entier positif. `dc.handle_outliers` met à NaN toute valeur physiquement impossible (score négatif ou absurde).
- **Matchs non joués** — 72 rencontres de la Coupe du Monde 2026 sont déjà au calendrier mais **n'ont pas encore de score**. Leur résultat étant inconnu, on les retire du jeu d'entraînement, mais on les **conserve à part** : ce sont précisément les matchs que le modèle devra prédire (objectif final du projet).

4.0.e 5. Imputation des valeurs manquantes

- **Classements FIFA** — environ 5 % des équipes (sélections non membres de la FIFA : Catalogne, Zanzibar...) n'ont pas de classement. On leur attribue un rang fictif « non classé » (**220**, au-delà du dernier rang réel qui est 211) et **0** point.

- **Tirs au but** — une valeur manquante signifie simplement « pas de séance de tirs au but ». On rend cette absence explicite avec la valeur `Aucun`.

4.0.f 6. Sauvegarde des données propres

On enregistre deux fichiers dans `data/processed/` :

- `matches_clean.csv` — les matchs joués, nettoyés, prêts pour l’exploration (étapes 3 et 4) ;
- `matches_a_predire.csv` — les matchs futurs de la CDM 2026, mis de côté pour la prédiction finale.

5 Visualisation Multidimensionnelle (Insights)

Nous présentons ici les résultats visuels clés permettant de dégager des insights exploitables pour les décideurs, en s’appuyant sur notre module `src/utils_viz.py`.

5.1 Chapitre 3 : Travaux Pratiques d’Exploration Visuelle

6 Étape 3 : Visualisation — l’histoire du football international

Cette étape est consacrée à la visualisation. On explore l’**histoire du football international** à travers six graphiques, à l’aide de notre module `src/utils_viz.py`.

Donnée d’entrée : `data/raw/results.csv` — l’historique **complet** des matchs (1872 → 2026). Ces visualisations décrivent l’histoire du football : elles utilisent toutes les données disponibles, et non la seule période d’entraînement du modèle (1992+).

6.0.a 1. Préparation de l’environnement

6.0.b 2. Chargement et préparation

On charge l’historique complet des matchs, on écarte les rencontres non encore jouées, puis on enrichit le tableau avec `dc.feature_engineering` (`year`, `decade`, `total_goals...`). On prépare aussi la liste des **tournois majeurs**.

6.0.c 3. Nombre de matchs par année

L’activité footballistique année par année. Les deux guerres mondiales et la pandémie de Covid-19 ressortent comme des **creux nets** dans le nombre de matchs.

6.0.d 4. Tournois avec le plus de matchs

Les compétitions qui ont accueilli le plus grand nombre de rencontres dans l’histoire (matchs amicaux exclus : ce ne sont pas un tournoi).

6.0.e 5. Équipes les plus présentes en tournois majeurs

Parmi les grands tournois (Coupe du Monde et championnats continentaux), quelles sélections ont disputé le plus de matchs ?

6.0.f 6. Nombre moyen de buts par match et par décennie

Le football est-il devenu plus ou moins offensif au fil des décennies ?

6.0.g 7. Meilleurs ratios de victoires en tournois majeurs

Les sélections les plus performantes dans les grands tournois — ratio victoires / matchs joués —, parmi celles ayant disputé au moins 30 matchs majeurs (seuil qui écarte les ratios non significatifs).

6.0.h 8. Évolution du pourcentage de matchs joués par jour de la semaine

Sept *small multiples*, un par jour de la semaine, montrent la part de matchs disputés ce jour-là année après année, jusqu'à 2018 exclu (on écarte les années marquées par la pandémie de Covid-19 et celles encore en cours). On distingue ainsi nettement les jours « traditionnels » du football international.

7 Analyse Exploratoire des Données (EDA)

Dans cette section, nous analysons les relations statistiques fondamentales qui régissent votre domaine d'étude au sein du jeu de données.

7.1 Chapitre 4 : Travaux Pratiques d'Exploration (EDA)

8 Étape 4 : Analyse Exploratoire des Données (EDA)

Cette étape **clôt le Jalon 1**. L'objectif : explorer et résumer les propriétés statistiques de nos données, les enrichir par **feature engineering**, et dégager les **insights majeurs** qui guideront la modélisation.

Donnée d'entrée : `data/processed/matches_clean.csv` — les 30 511 matchs nettoyés (depuis 1992), classements FIFA inclus.

8.0.a 1. Préparation de l'environnement

8.0.b 2. Chargement des données nettoyées

On charge le jeu de données nettoyé issu de l'étape 2 (Data Wrangling).

8.0.c 3. Statistiques descriptives

Résumé statistique global des variables numériques, puis une analyse par groupe : les buts marqués selon que le match se joue sur terrain neutre ou non.

8.0.d 4. Distribution des variables numériques

Avant de croiser les variables, on examine la **distribution univariée** de chacune des principales variables numériques (chapitres 4.2.1 *Tendance Centrale* et 4.2.2 *Dispersion* du cours). Pour chaque variable, l'histogramme est superposé d'une courbe **KDE** (densité lissée) et de deux lignes verticales : la **moyenne** (rouge) et la **médiane** (verte).

L'écart entre moyenne et médiane est un indicateur direct de l'**asymétrie** de la distribution (chapitre 4.2.4, *moyenne vs médiane*). Pour une distribution symétrique, les deux se confondent. Pour une distribution **asymétrique à droite** (cas typique des compteurs de buts : beaucoup de

petits scores, quelques scores énormes), la moyenne est tirée vers les valeurs extrêmes alors que la médiane reste centrale.

8.0.e 5. Ingénierie de variables (Feature Engineering)

On applique `dc.feature_engineering` pour créer les variables dérivées : indicateurs temporels (`year`, `decade`), variables de match (`goal_difference`, `total_goals`), écart de classement FIFA (`rank_difference`) et la **variable cible** `result` (victoire domicile / nul / victoire extérieur).

8.0.f 6. Distribution de la cible — `result`

La variable cible `result` a trois modalités : `home_win`, `draw`, `away_win`. Le **count plot** ci-dessous visualise leur fréquence et confirme un **déséquilibre marqué** : les victoires à domicile dominant ($\approx 48\%$), suivies des victoires extérieures ($\approx 28\%$), les matchs nuls étant minoritaires ($\approx 23\%$).

Ce déséquilibre devra être pris en compte au Jalon 2 (par exemple via `class_weight='balanced'` ou un échantillonnage stratifié).

8.0.g 7. Boxplots — dispersion par classe de résultat

Le **boxplot** (chapitre 4.2.2 du cours, *dispersion*) est la façon la plus directe de comparer la dispersion d'une variable numérique entre plusieurs groupes. La boîte représente l'**intervalle interquartile** (IQR : 25^e $\rightarrow$ 75^e percentile), la barre centrale la **médiane**, et les points isolés les **outliers**.

On compare ici la dispersion de `goal_difference` (écart de buts) et `total_goals` (intensité offensive du match) selon le résultat. On s'attend à voir un `goal_difference` très négatif pour les victoires extérieures, très positif pour les victoires à domicile, et serré autour de 0 pour les nuls.

8.0.h 8. Analyse des corrélations

On mesure les liens entre variables numériques avec deux coefficients : **Pearson** (relations linéaires) et **Spearman** (relations monotones, plus robuste aux valeurs extrêmes). Le point d'intérêt : l'écart de classement FIFA (`rank_difference`). *Couvre §4.3.2 du cours.*

8.0.i 9. Pairplot — vision globale des relations

Le **pairplot** (chapitre 4.3.1 du cours) est l'outil classique pour visualiser **toutes les relations bivariées** entre quelques variables clés, avec la distribution univariée sur la diagonale. Ici, on colore chaque point par le **résultat du match** : on voit immédiatement les zones où chaque classe (`home_win`, `away_win`, `draw`) se concentre.

On échantillonne **2 000 matchs aléatoires** : le pairplot complet sur 30 511 points serait très lent à rendre et illisible.

8.0.j 10. Matrice de corrélation massive (toutes les variables)

Pour aller plus loin que les seules variables numériques de la section précédente, on encode **toutes** les variables qualitatives (texte, booléen, catégorie) en codes catégoriels (`.astype('category').cat.codes`), puis on calcule la matrice de corrélation complète. La heatmap met ainsi en lumière les éventuelles structures cachées impliquant `home_team`, `away_team`, `tournoiement`, `city`, `country`, `result`, etc.

⚠ Les codes catégoriels sont arbitraires (ordre alphabétique des modalités). Les coefficients impliquant ces variables encodées signalent des **dépendances éventuelles**, pas une relation linéaire interprétable — à manipuler avec précaution.

8.0.k 11. Le classement FIFA prédit-il le résultat ?

On croise l'issue du match avec le fait que l'équipe à domicile soit, ou non, mieux classée que son adversaire — un premier aperçu du pouvoir prédictif du classement. C'est un cas typique de *split-apply-combine* (chapitre 4.4.1 du cours).

8.0.l 12. Pivot table — taux de victoire croisé

Au-delà du simple `groupby`, le **pivot table** (chapitre 4.4.2 du cours) permet de croiser deux dimensions et de visualiser l'effet conjoint sur une troisième. Ici, on croise :

- **lignes** : `tournoi_majeur` (Coupe du Monde / continentaux / Confederations Cup, ou autre) ;
- **colonnes** : `neutral` (terrain neutre ou non) ;
- **cellules** : taux de victoire à domicile (%).

C'est la façon la plus directe de confirmer que l'**avantage à domicile disparaît effectivement sur terrain neutre**, et de voir si la nature du tournoi joue un rôle indépendant.

8.0.m 13. Binning — taux de victoire par classe d'écart de classement

Au-delà du simple binaire « mieux classé / moins bien classé » étudié en section 11, on découpe `rank_difference` en 5 classes via `pd.cut` (chapitre 4.4.3 du cours, *binning / discrétisation*). Le bar plot révèle une **progression monotone** du taux de victoire à domicile en fonction de l'écart de classement — un signal très exploitable pour la modélisation au Jalon 2.

8.0.n 14. Synthèse — insights majeurs

À l'issue de l'exploration, cinq constats structurent la suite du projet :

1. **Avantage du terrain marqué.** L'équipe à domicile l'emporte dans **48,5 %** des matchs (contre 28,1 % pour l'extérieur et 23,3 % de nuls). Sur terrain neutre, l'écart de buts se réduit nettement (1,56 contre 1,35, contre 1,70 contre 1,02 à domicile).
2. **Le classement FIFA est le signal le plus fort.** Quand l'équipe à domicile est mieux classée que son adversaire, elle gagne **64,7 %** du temps ; quand elle est moins bien classée, ce taux chute à 31,1 % (et elle perd 43,3 % du temps). Le binning par classes d'écart confirme une progression nettement monotone.
3. **L'écart de classement est corrélé à l'écart de buts** (Pearson 0,47, Spearman 0,48) : plus le fossé de classement est grand, plus la victoire tend à être large.
4. **Cible à trois classes déséquilibrée** : les victoires à domicile dominent. Ce déséquilibre devra être pris en compte lors de la modélisation (classe majoritaire).
5. **Pas de tendance temporelle** : les corrélations avec l'année sont quasi nulles (≈ 0) → l'année n'apportera pas d'information prédictive.

➡ Ces constats orientent le Jalon 2 : le **classement FIFA** et l'**avantage du terrain** seront les variables clés du futur modèle de prédiction.

9 Modélisation et Apprentissage

Le pipeline complet intègre à la fois la branche analytique tabulaire (Machine Learning) et la branche d'analyse visuelle ou de signaux complexes (Deep Learning CNN) :

```
graph TD
    A[Données Brutes Multi-Sources CSV/API] -->|Formatage & Alignement| B(data_clean.clean_dates)
    C[Données Externes Complémentaires] -->|Imputation & Interpolation| D(data_clean.impute_missing_values)
    B & D -->|Gestion Outliers| E[Jeu de données Propre & Fusionné]
    E -->|Extraction Temporelle/Caractéristiques| F[Feature Engineering]
    F -->|Splits Temporels ou Stratifiés| G[Modèle Machine Learning Tabulaire]
    H[Flux Multimédias Réels Images/Signaux] -->|Prétraitement d'images/signaux| I[Réseau Convolutif CNN TensorFlow]
    G -->|Prédictions de la Problématique Métier| J[Livrables & Aide à la Décision]
    I -->|Détection de Motifs Complexes| J

    style E fill:#e0f2fe,stroke:#0284c7,stroke-width:2px
    style J fill:#f0fdf4,stroke:#16a34a,stroke-width:2px
    style G fill:#fef3c7,stroke:#d97706,stroke-width:2px
    style I fill:#fef3c7,stroke:#d97706,stroke-width:2px
```

9.1 Chapitre 5 : Travaux Pratiques de Modélisation (ML & DL)

10 🧠 Étape 5 : Modélisation — Prédiction du résultat des matchs internationaux

Cette étape est le cœur du **Jalon 2**. On entraîne deux modèles d'apprentissage supervisé pour prédire l'issue d'un match (`home_win` / `draw` / `away_win`), avec en ligne de mire la **Coupe du Monde FIFA 2026**.

Donnée d'entrée : `data/processed/matches_clean.csv` — 30 511 matchs nettoyés (1993 → mars 2026), classements FIFA inclus.

Approche — alignée sur le chapitre 5 du cours :

- Tâche : **classification multi-classes** sur données tabulaires (§5.2 du cours).
- Deux modèles, exactement ceux que le cours implémente en Python :
 - **Random Forest** — méthode d'ensemble par *Bagging* (§5.6.1) ;
 - **XGBoost** — méthode d'ensemble par *Boosting* (§5.6.2).

- Concepts clés (§5.7) mobilisés : compromis biais-variance, sur-ajustement, importance d'une baseline.

Deux apports de cette version :

1. un *feature engineering* enrichi — on reconstruit l'**historique réel de chaque équipe** (buts marqués/encaissés, forme récente, force des adversaires) ;
2. une **analyse par groupe** — on applique le modèle aux 72 matchs de la phase de groupes de la CDM 2026 et on dresse le **classement des 12 groupes**.

10.0.a 1. Préparation de l'environnement

10.0.b 2. Feature engineering — l'historique de chaque équipe

Le classement FIFA seul est une photo figée : il ne dit rien de la **dynamique** d'une équipe (attaque prolifique ? défense fragile ? bonne forme récente ?). On reconstruit donc, pour chaque match, le passé de chaque équipe.

Méthode — table « longue ». Chaque match est dédoublé en deux lignes (une par équipe), pour suivre chaque sélection comme un fil chronologique :

Variable construite	Signification
<code>goals / goals_suf</code>	buts marqués / encaissés par l'équipe ce match-là
<code>game_points</code>	points du match (3 victoire / 1 nul / 0 défaite)
<code>game_points_rank</code>	points pondérés par la force de l'adversaire : battre le 1 ^{er} mondial vaut bien plus que battre le 200 ^e

⚠ **Anti-fuite de données.** Toutes les moyennes seront **décalées d'un match** (`.shift(1)`) : un match ne « voit » jamais son propre résultat, uniquement ceux qui le précèdent.

10.0.b.a Moyennes glissantes par équipe

Pour chaque équipe, triée dans l'ordre chronologique, on calcule deux types de moyennes — toujours **décalées d'un match** :

- **moyenne sur tout le passé** (`expanding`) → le niveau de fond de l'équipe ;
- **moyenne sur les 5 derniers matchs** (`_15, rolling`) → la **forme récente**.

On obtient ainsi, pour chaque équipe : buts marqués (`goals_mean`), buts encaissés (`goals_suf_mean`), rang moyen des adversaires affrontés (`rank_mean`, une mesure de la difficulté du calendrier) et points pondérés (`game_points_rank_mean`).

10.0.c 3. Variables différentielles (`create_db`) et cible

Un modèle prédit mieux à partir d'**écarts** entre les deux équipes qu'à partir de valeurs absolues. On dérive donc, pour chaque indicateur, la différence domicile – extérieur — c'est la logique de la fonction `create_db` du notebook Kaggle de référence.

12 variables explicatives finales :

Variable	Sens
<code>rank_dif</code>	écart de classement FIFA actuel
<code>goals_dif / goals_dif_l5</code>	écart d'attaque (global / forme récente)
<code>goals_suf_dif / goals_suf_dif_l5</code>	écart de fragilité défensive
<code>goals_per_ranking_dif</code>	efficacité offensive corrigée de la force du calendrier
<code>dif_rank_agst / dif_rank_agst_l5</code>	écart de difficulté des adversaires affrontés
<code>dif_points_rank / dif_points_rank_l5</code>	écart de performance pondérée par la force adverse
<code>is_friendly_0 / is_friendly_1</code>	match amical ou enjeu réel (one-hot)

La **cible** `result` est déduite directement des scores (`0 = away_win`, `1 = draw`, `2 = home_win`). Les scores eux-mêmes (`home_score`, `away_score`) ne sont **jamais** donnés au modèle : ce serait une fuite de données évidente.

10.0.c.a Séparation entraînement / test

On encode la cible numériquement puis on réalise un **split stratifié 80/20** (les proportions de classes sont conservées dans les deux jeux). Le jeu de test ne sera utilisé qu'à la toute fin, pour mesurer la capacité de **généralisation** des modèles (§5.7 du cours).

10.0.d 4. Baseline naïve

Avant tout modèle ML, on établit la performance d'un **prédicteur trivial** qui prédit toujours la classe majoritaire (`home_win`). C'est la référence à battre : sans elle, impossible de savoir si un modèle apprend réellement quelque chose (cf. §5.7 du cours).

10.0.e 5. Modèle 1 — Random Forest (§5.6.1 du cours, *Bagging*)

« Le Bagging consiste à entraîner de nombreux modèles de manière indépendante et en parallèle sur des sous-ensembles aléatoires de vos données. C'est un jury d'assises. [...] La Forêt Aléatoire crée des centaines d'arbres de décision. Force : très robuste contre le sur-ajustement. »

On instancie exactement comme le cours, en ajustant `n_estimators` et `max_depth` pour notre volume de données. `class_weight='balanced'` compense le déséquilibre des classes observé en EDA.

10.0.f 6. Modèle 2 — XGBoost (§5.6.2 du cours, *Boosting*)

« Le Boosting fonctionne de manière séquentielle. Chaque nouvel arbre est construit spécifiquement pour corriger les erreurs (les résidus) des précédents. XGBoost : le standard industriel, ultra-optimisé et régularisé. »

On instancie `XGBClassifier` exactement comme dans le cours (`n_estimators=100`, `learning_rate=0.1`). XGBoost gère nativement les cibles multi-classes.

10.0.g 7. Comparaison des modèles + matrice de confusion

On compare les deux modèles sur le jeu de **test** (jamais vu pendant l'entraînement), et on visualise la **matrice de confusion** du meilleur d'entre eux pour identifier ses erreurs typiques — en particulier sur les matchs nuls, la classe minoritaire.

10.0.h 8. Importance des variables

Le Random Forest expose nativement l'**importance de chaque variable** (importance de Gini). On vérifie ainsi quelles caractéristiques pèsent réellement dans la décision : les variables d'historique enrichi (buts, points pondérés) apportent-elles plus que le simple classement ?

10.0.i 9. Prédiction des 72 matchs de la phase de groupes (CDM 2026)

On applique le meilleur modèle aux **72 matchs programmés de la phase de groupes** (`data/processed/matches_a_predire.csv`) — soit les 48 équipes réparties en 12 groupes de 4.

Pour chaque équipe, on calcule sa **forme actuelle** : les mêmes moyennes (buts, points pondérés, force du calendrier) mais cette fois sur l'**intégralité** de son historique connu, jusqu'à mars 2026. On reconstruit les 12 variables différentielles, puis on prédit l'issue de chaque match ainsi que les **probabilités** des trois résultats possibles.

10.0.j 10. Classement des 12 groupes — qui sort de sa poule ?

On reconstitue maintenant le **classement de chaque groupe** à partir des prédictions. La répartition officielle des 48 équipes (tirage du 5 décembre 2025) est fournie par le module `src/wc2026.py`.

Comment on classe les équipes ? Comme dans un vrai classement de football : **par points** (3 victoire / 1 nul / 0 défaite), à partir des 6 matchs internes au groupe.

Problème : le modèle prédit très rarement le match nul, donc beaucoup d'équipes terminent à **égalité de points**. On les départage avec les **points espérés** (`xPts`) :

$$xPts = \sum_{3 \text{ matchs}} (3 \times P(\text{victoire}) + 1 \times P(\text{nul}))$$

C'est l'**espérance mathématique** du nombre de points, compte tenu des probabilités du modèle. `xPts` joue ici le rôle que tient la différence de buts dans un vrai classement — un critère fin que notre modèle (qui prédit une *issue*, pas un *score*) ne peut pas fournir directement.

Format CDM 2026 : les **2 premiers** de chaque groupe + les **8 meilleurs 3^{es}** se qualifient → 32 équipes pour les 16^{es} de finale. C'est cette liste qui servira de point de départ au notebook 06.

10.0.j.a Vainqueurs de groupe et équipes qualifiées

10.0.k 11. Synthèse — modélisation

1. **Les deux modèles battent largement la baseline naïve (~48.5 %)** : le *feature engineering* enrichi (historique de buts, forme récente, force du calendrier) apporte un vrai signal prédictif.
2. **Le passage du classement FIFA seul aux 12 variables différentielles fait progresser la précision de test** — voir le tableau récapitulatif du §7. Les variables d'historique (`dif_points_rank`, `goals_per_ranking_dif`, `goals_suf_dif`) figurent en tête de l'importance, aux côtés du `rank_dif`.
3. **Random Forest et XGBoost** restent au coude-à-coude, conformément à la littérature sur les données tabulaires (§5.1 du cours : *les arbres dominant encore le tabulaire face au Deep Learning*).
4. **Phase de groupes CDM 2026** : les 72 matchs sont prédits, puis agrégés en **classement des 12 groupes** via les points espérés (`xPts`). On en déduit les 12 vainqueurs de groupe et les 32 **équipes qualifiées** pour les 16^{es} de finale.
5. **Limites identifiées** : la classe `draw` reste sous-prédite (matchs nuls intrinsèquement difficiles) ; chaque match est prédit indépendamment.

➡ Le notebook suivant (`06_evaluation`) approfondira l'évaluation (validation croisée temporelle, métriques par classe) puis exploitera la liste des 32 qualifiés pour **simuler la phase à élimination directe** et désigner le vainqueur de la Coupe du Monde.

11 Évaluation Métrique et Validation

Au-delà de l'*accuracy* — que le cours qualifie de « métrique de vanité » — le modèle est évalué avec la batterie d'indicateurs adaptés aux classes déséquilibrées : matrice de confusion, précision, rappel, F1-score et ROC-AUC. Les hyperparamètres sont ensuite optimisés par recherche aléatoire en validation croisée. Le modèle ainsi validé est enfin appliqué au **bracket officiel de la phase à élimination directe** : la simulation des 16^{es} de finale jusqu'à la finale, complétée par une validation Monte-Carlo (20 000 tirages), désigne le **champion du monde 2026 prédit** et quantifie l'incertitude de la compétition.

11.1 Chapitre 6 : Travaux Pratiques d'Évaluation & Robustesse

12 🧪 Étape 6 : Évaluation et phase à élimination directe

Sixième étape du pipeline, alignée sur le **chapitre 6 du cours** (« Évaluation des Modèles »). Elle poursuit deux objectifs :

1. **Évaluer rigoureusement** le modèle du notebook 05 — au-delà de la simple *accuracy*, avec les métriques que le cours juge indispensables : matrice de confusion, précision, rappel, F1-score, ROC-AUC (§6.1), puis optimisation des hyperparamètres (§6.2).
2. **Simuler la phase à élimination directe** de la Coupe du Monde 2026 — appliquer le modèle évalué au bracket officiel (16^{es} de finale → finale) pour répondre à la question finale du projet : **qui sera champion du monde ?**

Données d'entrée : `matches_clean.csv` (entraînement) et `cdm2026_qualifies.csv` — les 32 équipes qualifiées produites par le notebook 05.

12.0.a 1. Préparation de l'environnement

12.0.b 2. Reprise du modèle du notebook 05

On reconstruit ici le **meilleur modèle du notebook 05** (XGBoost) : on recharge les 30 511 matchs, on réapplique le *feature engineering* enrichi (historique de chaque équipe : buts, forme récente, force des adversaires → 12 variables différentielles), puis on ré-entraîne XGBoost sur le **même split stratifié 80/20** pour garantir la cohérence avec le notebook précédent.

12.0.c 3. Évaluation approfondie du modèle (§6.1 du cours)

« En 2026, l'industrie a enfin compris que l'Accuracy est souvent une métrique de vanité. » — chapitre 6 du cours.

L'accuracy seule ne suffit pas, surtout sur des **classes déséquilibrées** (ici `home_win` 48 %, `away_win` 28 %, `draw` 23 %). On mobilise donc la batterie de métriques du cours :

- **Matrice de confusion** — le « bilan sanguin » du modèle : où se trompe-t-il ?
- **Précision** (sur mes alertes, combien sont vraies ?) et **Rappel** (sur les cas réels, combien j'en capture ?), par classe.
- **F1-score** — moyenne harmonique précision/rappel, indispensable en classes déséquilibrées.
- **ROC-AUC** — capacité du modèle à séparer les classes (1.0 = parfait, 0.5 = hasard).

12.0.d 4. Optimisation des hyperparamètres (§6.2 du cours)

Les hyperparamètres (`n_estimators`, `max_depth`, `learning_rate`...) ne sont pas appris par le modèle : on les règle nous-mêmes. Le cours présente trois approches : **Grid Search**, **Random Search**, et l'**optimisation bayésienne** (Optuna, devenu le standard 2026).

On applique ici un **Random Search** via `RandomizedSearchCV` de scikit-learn : il échantillonne des combinaisons au hasard et les évalue en **validation croisée 3 plis**. Plus rapide qu'un Grid Search exhaustif, sans dépendance supplémentaire.

💡 *Le cours recommande Optuna (algorithme TPE) pour les projets de production : il « apprend » de ses essais précédents au lieu de chercher à l'aveugle. Random Search reste suffisant pour notre volume de données.*

12.0.e 5. Phase à élimination directe — qui sera champion du monde ?

On applique maintenant le modèle au **bracket officiel de la CDM 2026** (source : Wikipédia, 2026 *FIFA World Cup knockout stage*), encodé dans `src/wc2026.py` : 16^{es} de finale (32 équipes) → 8^{es} → quarts → demies → **finale**.

Trois principes de simulation :

1. **Neutralisation de l'avantage du terrain.** En phase finale, les matchs sont sur terrain neutre. Comme le modèle a appris un fort avantage à domicile, on prédit chaque match **dans les deux sens** (A reçoit B, puis B reçoit A) et on **moyenne** les probabilités. L'asymétrie domicile/extérieur s'annule.
2. **Pas de match nul possible.** Un match à élimination directe a forcément un vainqueur : la probabilité de nul est redistribuée, et l'équipe la plus probable se qualifie (le nul correspondrait à une qualification aux tirs au but, qui favorise statistiquement le favori).
3. **Affectation des 8 troisièmes.** La FIFA place les 8 meilleurs 3^{es} via une table de combinaisons. On calcule une **affectation valide** respectant les contraintes d'éligibilité de chaque match des 16^{es}.

12.0.e.a 5.1 Simulation déterministe du bracket

À chaque tour, on fait avancer l'équipe la **plus probable**. On déroule ainsi les 16^{es} jusqu'à la finale.

12.0.e.b Le parcours du champion

12.0.e.c 5.2 Robustesse — probabilités de titre par Monte-Carlo

La simulation déterministe désigne un seul champion, mais elle ignore les **surprises** (un favori à 60 % perd tout de même 4 fois sur 10). Pour mesurer la **robustesse** de la prédiction, on rejoue le tournoi **un grand nombre de fois** : à chaque match, le vainqueur est tiré au hasard selon sa probabilité. La fréquence de victoire finale de chaque équipe donne sa **probabilité de titre**.

12.0.f 6. Synthèse — évaluation et prédiction finale

1. **Au-delà de l'accuracy** (§6.1 du cours) : la matrice de confusion et le F1-score confirment un modèle solide sur `home_win` / `away_win` mais quasi aveugle sur les matchs nuls (`draw`) — limite intrinsèque, le nul étant peu prévisible.
2. **Optimisation des hyperparamètres** (§6.2) : le Random Search en validation croisée 3 plis n'apporte qu'un gain marginal — le modèle de base XGBoost était déjà bien réglé.
3. **Phase à élimination directe** : en appliquant le modèle au bracket officiel (avantage du terrain neutralisé), on simule l'intégralité du tournoi des 16^{es} de finale jusqu'à la finale.
4. **Prédiction finale** : le modèle désigne un **champion du monde 2026** ; la validation **Monte-Carlo** (20 000 simulations) confirme qu'il s'agit du favori le plus probable, tout en quantifiant l'incertitude réelle de la compétition.
5. **Limites** : pas de gestion des blessures, suspensions ni dynamique de tournoi ; le modèle reste une estimation probabiliste — le football garde sa part d'imprévu.

➡ Le notebook `07_communication` restituera ces résultats sous forme de *data storytelling* à destination d'un public non technique.

13 Data Storytelling et Communication

13.1 Chapitre 7 : Travaux Pratiques de Storytelling

14 📌 Étape 7 : Data Storytelling & Communication (Squelette Étudiant)

Cette étape correspond au septième et dernier chapitre de data science. L'objectif est de synthétiser vos résultats pour des profils métiers ou décideurs et de proposer des visualisations interactives ou dynamiques pour valoriser vos conclusions.

14.0.a 1. Préparation de l'environnement

14.0.b 2. Synthèse métier et Storytelling

À COMPLÉTER PAR L'ÉTUDIANT : Traduisez vos métriques techniques en impacts stratégiques (par exemple, gains financiers, réduction de coûts, amélioration de la sécurité, etc.).

14.0.c 3. Visualisation Interactive (Plotly)

À COMPLÉTER PAR L'ÉTUDIANT : Générez un graphique interactif (par exemple en utilisant Plotly ou des éléments OJS dans le document final) pour permettre aux décideurs d'interagir dynamiquement avec vos données.

14.1 Présentation des Résultats (Livrables Interactifs)

14.1.a 📺 Diaporama de Soutenance (RevealJS)

Ci-dessous est intégré le squelette de votre diaporama de soutenance RevealJS. Utilisez-le pour présenter votre démarche aux décideurs de façon professionnelle.

14.1.b 📊 Exemple de Dashboard Dynamique (OJS / Plotly)

Voici un exemple minimal de code montrant comment intégrer un graphique dynamique contrôlé par un composant d'interface utilisateur en Observable JS (OJS).

```
//| echo: true
// Boutons de sélection interactifs OJS
viewof selectedCategory = Inputs.select(["Toutes", "A", "B", "C"], {value:
"Toutes", label: "Filtrer par Catégorie :"})
```

```
//| echo: false
// Données simulées réactives
data = [
  {timestamp: "2026-05-18T00:00:00Z", value: 10.5, category: "A"},
  {timestamp: "2026-05-18T02:00:00Z", value: 12.1, category: "A"},
  {timestamp: "2026-05-18T04:00:00Z", value: 14.7, category: "A"},
  {timestamp: "2026-05-18T05:00:00Z", value: 15.2, category: "A"},
```

```

    {timestamp: "2026-05-18T06:00:00Z", value: 16.0, category: "B"},
    {timestamp: "2026-05-18T07:00:00Z", value: 18.3, category: "B"},
    {timestamp: "2026-05-18T09:00:00Z", value: 21.5, category: "B"},
    {timestamp: "2026-05-18T10:00:00Z", value: 22.0, category: "B"},
    {timestamp: "2026-05-18T12:00:00Z", value: 25.4, category: "C"},
    {timestamp: "2026-05-18T13:00:00Z", value: 26.1, category: "C"},
    {timestamp: "2026-05-18T15:00:00Z", value: 28.9, category: "C"},
    {timestamp: "2026-05-18T16:00:00Z", value: 30.2, category: "C"}
  ]

  // Filtrage réactif de la donnée
  filteredData = selectedCategory === "Toutes"
    ? data
    : data.filter(d => d.category === selectedCategory)

  // Tracé interactif avec la librairie Plotly
  Plotly.newPlot('dynamic-chart', [{
    x: filteredData.map(d => d.timestamp),
    y: filteredData.map(d => d.value),
    type: 'scatter',
    mode: 'lines+markers',
    marker: {color: '#1A73E8', size: 8},
    line: {shape: 'spline', color: '#1A73E8', width: 3}
  }], {
    title: 'Évolution Dynamique des Valeurs (Filtrée)',
    margin: {t: 50, b: 50, l: 50, r: 50},
    paper_bgcolor: 'rgba(0,0,0,0)',
    plot_bgcolor: 'rgba(0,0,0,0)',
    xaxis: {gridcolor: '#E5E7EB'},
    yaxis: {gridcolor: '#E5E7EB'}
  })
})

```

15 Utilisation de l'Intelligence Artificielle

Dans une démarche de transparence scientifique et académique, cette section détaille la manière dont les outils d'Intelligence Artificielle (IA) générative ont été intégrés tout au long de la réalisation de ce projet.

15.1 Cartographie de l'utilisation de l'IA

Outil d'IA	Cas d'usage (Pourquoi ?)	Méthode d'utilisation (Comment ?)	Rôle et Validation Humaine
[Outil d'IA]	[À compléter par les étudiants]	[À compléter par les étudiants]	[À compléter par les étudiants]

15.2 Principes de Rigueur et Responsabilité

1. **Responsabilité intellectuelle** : L'équipe assume l'entière responsabilité des analyses, des choix de modèles et des conclusions présentées dans ce rapport.
 2. **Lutte contre les hallucinations** : Chaque suggestion technique a fait l'objet d'une validation empirique.
 3. **Protection des données** : Aucun jeu de données confidentiel ou sensible n'a été soumis à des modèles tiers en ligne.
-

Bibliographie

Bibliography

- [1] W. McKinney, *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media, 2020.